

(4,8)(8,1)

(128,128)(1,128)


LEETCUDA

CUDA KERNEL 优化之路

从编程模型到 CUTE 与 FLASHATTENTION

((2,2),(2,2))

(3):(1)



$$L = (8,16):(1,8)$$

(16,8)(8,1)

(8,16)(1,8)

```
auto tiled_mma = make_tiled_mma(SM80_16x8x16_F32F16F16F32_TN{}, Layout<Shape<_2,_2,_1>>{});
```

郑重声明

本书仅用于开源学习与技术交流，
未经作者本人同意，不得用于任何商业用途。