(4,8):(8,1)

(128,128):(1,128)

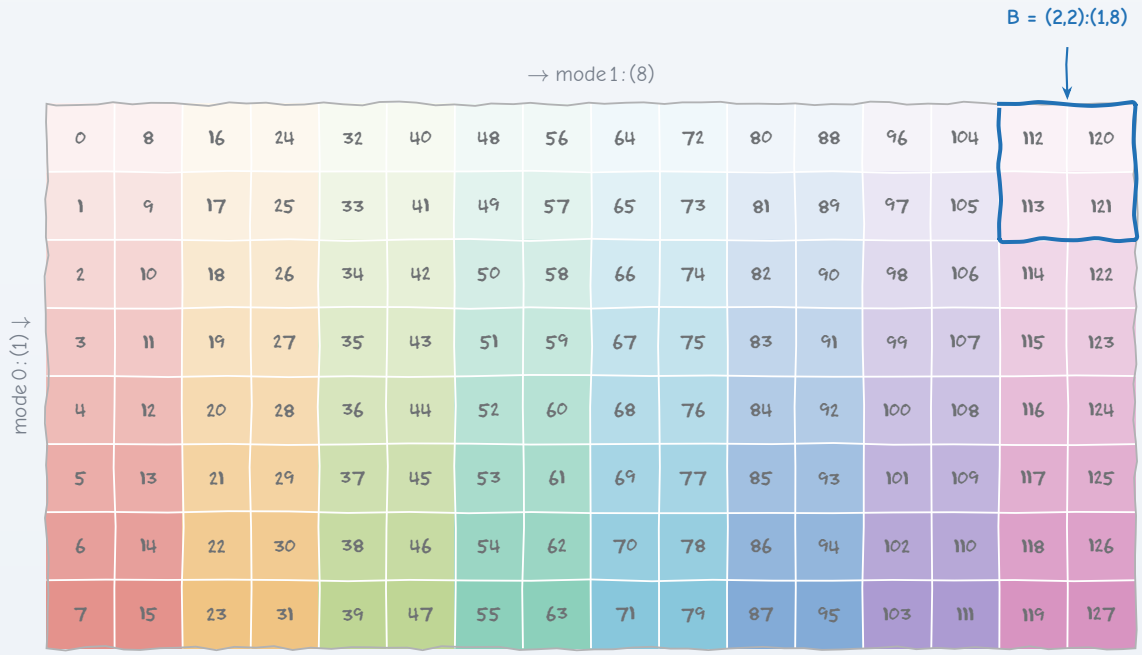
LEETCUDA

CUDA KERNEL 优化之路

从编程模型到 CUTE 与 FLASHATTENTION

((2,2),(2,2))

(3):(1)



L = (8,16):(1,8)

(16,8):(8,1)

(8,16):(1,8)

```
auto tiled_mma = make_tiled_mma(SM80_16x8x16_F32F16F16F32_TN{}, Layout<Shape<_2,_2,_1>>{});
```

郑 重 声 明
本 书 仅 用 于 开 源 学 习 与 技 术 交 流，
未 经 作 者 本 人 同 意， 不 得 用 于 任 何 商 业 用 途。